

Observatório do Mercado de Trabalho em Ciência de Dados no Brasil:

Coleta Multi-Fonte, Unificação de Dados e Análise Salarial

Richard Elias Soares Viana

Observatório de Empregos — Extensão IMPA-Tech

erichardsv1234@gmail.com

Julho de 2026

Resumo

Este relatório descreve a arquitetura de coleta, unificação e limpeza de dados do Job Data Observatory, um sistema de código aberto que consolida vagas e referências salariais de Ciência de Dados no Brasil a partir de cinco fontes heterogêneas (LinkedIn, Glassdoor, Catho, portais Gupy e uma base curada manualmente), e apresenta a análise mais recente do mercado gerada a partir dessa base unificada. Descrevemos a metodologia de normalização de esquema, a classificação de cargo/senioridade por vocabulário de expressões regulares compartilhado entre fontes, e um conjunto de correções de qualidade de dados identificadas durante a auditoria do pipeline (falsos positivos de regex, colunas de origem corrompidas e valores salariais implausíveis). A base unificada resultante contém 5.252 registros, com cobertura de salário de 97,5% (ante 3,2% antes da integração das fontes adicionais). Os resultados mostram uma progressão salarial de quase 10× entre estágio e posições de staff, uma concentração de vagas em São Paulo, e um prêmio salarial de 58% para vagas remotas frente a presenciais. Discutimos as limitações da amostra, em particular o viés de composição entre vagas individuais e referências agregadas de salário.

Palavras-chave: mercado de trabalho, ciência de dados, engenharia de dados, unificação de dados, análise salarial, Brasil.

1 Introdução

O mercado brasileiro de Ciência de Dados carece de fontes de dados públicas, atualizadas e consolidadas sobre remuneração, distribuição geográfica e modalidade de trabalho. Portais de emprego e de referência salarial (LinkedIn, Glassdoor, Catho, plataformas baseadas em Gupy) publicam informações parciais, em formatos distintos e sem interoperabilidade entre si. O *Job Data Observatory* foi criado como projeto de extensão do IMPA-Tech para preencher essa lacuna: um sistema que coleta dados de múltiplas fontes, os normaliza para um esquema unificado, e os disponibiliza por meio de um painel interativo e um mecanismo de busca semântica.

Este relatório tem dois objetivos. Primeiro, documentar a metodologia de coleta e unificação de dados, incluindo um conjunto de correções de qualidade aplicadas durante uma auditoria completa do pipeline — a maioria das fontes manualmente coletadas (*data_preprocess/*) estava, até esta revisão, coletada mas nunca efetivamente incorporada à base final. Segundo, apresentar a análise mais atual do mercado, obtida a partir da base unificada resultante.

2 Metodologia

2.1 Fontes de Dados

A base unificada combina cinco fontes independentes, cada uma processada por um carregador dedicado que

mapeia seus campos originais para um esquema comum de 16 colunas (*company*, *role*, *seniority*, *region*, *work_model*, *contract_type*, *salary*, entre outras). A Tabela 1 resume a composição da base.

Table 1: Composição da base unificada por fonte.

Fonte	Registros	Natureza
Glassdoor	4.698	Referência salarial agregada
Salário Transparente	497	Vaga individual
Portais Gupy	41	Vaga individual
Catho	16	Vaga individual
Total	5.252	—

O LinkedIn (*job_scrapper/*) é uma sexta fonte planejada, coletada via Selenium; como exige uma sessão autenticada e está sujeita aos termos de uso da plataforma, o pipeline de unificação foi projetado para funcionar *sem* essa fonte — caso o arquivo de coleta não exista, o carregador correspondente é ignorado com um aviso, em vez de interromper todo o processo.

Note-se que 89,4% dos registros vêm do Glassdoor, que reporta *benchmarks* de salário por combinação empresa/cargo, não vagas abertas no momento da coleta. Essas linhas são mantidas 1:1 (não expandidas pelo número de relatos salari-

ais subjacente) para evitar distorção nas estatísticas de contagem de vagas, mas isso implica que a base mistura duas naturezas de registro distintas — ponto retomado na Seção 4.

2.2 Pipeline de Unificação

O módulo `data_treatment/merge_data_sources.py` orquestra a unificação em três etapas: (i) carregamento e normalização por fonte; (ii) classificação de `role` e `seniority` por vocabulário de expressões regulares compartilhado (`ROLE_REGEX`, `SENIORITY_REGEX`) entre todas as fontes, garantindo que a mesma vaga produza o mesmo rótulo independentemente de sua origem; e (iii) binarização da coluna `benefits` em colunas booleanas (`benefit_<nome>`) para consumo direto pelo painel.

Antes desta revisão, apenas a fonte *Salário Transparente* normalizava `role` pelo vocabulário compartilhado; as demais gravavam o cargo bruto em português, fragmentando os gráficos por cargo em dezenas de rótulos equivalentes (p.ex. “Analista de Dados Sênior” e “Data Analyst” como categorias distintas). A normalização foi estendida a todas as fontes.

2.3 Auditoria e Correções de Qualidade

A integração das fontes adicionais expôs três problemas de qualidade, corrigidos nesta revisão:

1. **Falso positivo geográfico.** O padrão de regex para o estado do Pará (`par[áa]pa`) também casa com a preposição portuguesa “para”, produzindo detecções incorretas de estado ao ser aplicado sobre texto livre (descrições de vaga). A extração de região foi restrita a campos estruturados de localização.
2. **Coluna de origem corrompida.** A coluna `empresa` do Catho continha texto de interface (“compartilhar”, “Idioma:”) em vez do nome da empresa, artefato do seletor CSS usado na coleta manual; a coluna é descartada nesta fonte em vez de propagar dados incorretos.
3. **Valores salariais implausíveis.** Um pequeno subconjunto de registros do Glassdoor (82 de 4.698) reportava salário médio mensal acima de R\$ 100.000 — provavelmente remuneração anual rotulada como mensal na fonte original. Esses valores são tratados como ausentes em vez de distorcer as distribuições salariais.

2.4 Vetorização Semântica

Para a busca semântica (`/api/search`), cada registro é convertido em uma representação textual combinando cargo, senioridade, região, modalidade, tecnologias, benefícios e uma versão truncada da descrição, codificada pelo modelo multilíngue `paraphrase-multilingual-mpnet-base-v2` (`sentence-transformers`) em vetores de 768 dimensões. Consultas do usuário são codificadas no mesmo espaço e ranqueadas por similaridade de cosseno contra a matriz de embeddings.

3 Resultados

3.1 Cobertura de Dados

A integração das fontes adicionais elevou a cobertura de salário de 3,2% (497 de 15.436 registros, estado anterior da base) para 97,5% (5.123 de 5.252). Localização e modalidade de trabalho, por virem majoritariamente de fontes manuais, têm cobertura bem menor: 9,9% e 10,3%, respectivamente. A base cobre 2.483 empresas distintas.

3.2 Salário por Senioridade

A Tabela 2 e a Figura 1 mostram a progressão salarial por nível. A diferença entre estágio (R\$ 2.813) e posições de staff (R\$ 27.941) é de quase 10×. O salto mais expressivo em termos proporcionais ocorre entre júnior e sênior (2,45×).

Table 2: Salário base por nível de senioridade.

Nível	n	Média (R\$)	Mediana (R\$)
Estágio	76	2.813	2.000
Júnior	865	5.646	5.000
Pleno	670	8.695	8.000
Sênior	875	13.805	13.000
Líder/Coordenador	54	19.163	18.000
Gerente	68	23.800	21.500
Staff	17	27.941	23.000
Não informado	2.493	9.072	7.000




Figure 1: Salário base médio por nível de senioridade.

3.3 Distribuição Geográfica

Entre os 520 registros que informam localização (Tabela 3), São Paulo concentra 57% das vagas geolocalizadas. Santa Catarina apresenta o maior salário médio entre os estados com amostra relevante, embora com apenas 17 registros.

Table 3: Top 8 estados por número de registros.

Estado	n	Média (R\$)	Mediana (R\$)
São Paulo	280	9.799	9.000
Rio de Janeiro	64	9.224	9.025
Minas Gerais	47	8.672	7.500
Paraná	38	7.079	6.500
Santa Catarina	17	11.834	8.000
Pernambuco	10	6.668	5.650
Ceará	9	6.770	5.796
Distrito Federal	9	8.193	8.000

3.4 Modalidade de Trabalho

Entre os 541 registros que informam modalidade (Tabela 4, Figura 2), vagas remotas pagam, em média, 58% a mais que vagas presenciais (R\$ 10.081 vs. R\$ 6.372).

Table 4: Salário base por modalidade de trabalho.

Modalidade	n	Média (R\$)	Mediana (R\$)
Remoto	270	10.081	9.000
Híbrido	191	9.060	8.270
Presencial	75	6.372	5.276




Figure 2: Distribuição de vagas por modalidade de trabalho.

3.5 Empresas e Benefícios

Bancos de grande porte (Bradesco, Itaú), varejo digital (iFood, Mercado Livre) e consultorias (Accenture, IBM) lideram em número de registros (Figura 3), refletindo tanto o tamanho dessas operações quanto sua presença consolidada em bases de referência salarial.



Figure 3: Top 10 empresas por número de registros.

Entre as 542 vagas que detalham benefícios, plano de saúde (79,0%), Gympass (72,3%) e vale-refeição (71,6%) são os mais recorrentes (Figura 4).



Figure 4: Top 10 benefícios mais recorrentes.

4 Discussão e Limitações

Três limitações merecem destaque para uma leitura criteriosa dos resultados. Primeiro, a base mistura vagas individuais com *benchmarks* agregados do Glassdoor (89,4% dos registros); estes últimos refletem estimativas de remuneração por empresa/cargo, não necessariamente posições abertas no momento da coleta. Segundo, a cobertura de campos é desigual: enquanto salário está presente em 97,5% dos registros, localização, modalidade e benefícios cobrem apenas ~10%, concentrados nas fontes manuais. Terceiro, a amostra é fortemente enviesada para o cargo de Cientista de Dados (92,9% dos registros), refletindo o escopo de coleta do observatório e da consulta usada no Glassdoor, não a proporção real desses cargos no mercado de tecnologia como um todo. Grupos com poucas observações (Staff, $n = 17$; Líder/Coordenador, $n = 54$) devem ser interpretados como direcionais.

5 Conclusão

A auditoria e extensão do pipeline de unificação elevaram a cobertura de salário da base de 3,2% para 97,5%, ao integrar três fontes manualmente coletadas que não estavam sendo aproveitadas, e corrigiram três problemas concretos de qualidade de dados (falso positivo geográfico, coluna de origem corrompida, outliers salariais implausíveis). A análise resultante confirma padrões esperados do mercado brasileiro de dados — progressão salarial acentuada por senioridade, concentração em São Paulo, prêmio para trabalho remoto — com transparência explícita sobre o tamanho de amostra por indicador. Trabalhos futuros devem priorizar a retomada da coleta via LinkedIn e a incorporação das submissões manuais (/vaga/nova) ao pipeline de unificação, hoje armazenadas separadamente.

Código-fonte, dados e o painel interativo completo estão disponíveis no repositório do projeto.